

# 朴素贝叶斯分类器

贝叶斯分类器是将数据  $X^i = \{x_1^i, x_2^i, \dots, x_d^i\}$  分类成  $Y = \{c_1, c_2, \dots, c_k\}$  的决策方法。不同于线性回归模型，贝叶斯分类器是一种生成式模型。机器学习主要有两种策略，

- 判别式模型：给定  $X$ ，可通过直接建模  $P(c|x)$  来预测  $c$
- 生成式模型：也可对联合概率分布  $P(x, c)$  建模，由此获得  $P(c|x)$

## 高斯判别法

高斯判别法是一种生成式模型，假设  $X \in R^d$ ， $X$  是连续属性的变量。

考虑二分类问题， $y$  满足伯努利分布

$$P(y) = \phi^y (1 - \phi)^{1-y}, \quad y = \{0, 1\}$$

利用极大似然法对  $y$  建模，可以得到参数  $\phi$  的取值

$$= \sum_{i=1}^m \frac{y^i - \phi}{\phi(1 - \phi)} = 0, \quad \phi = \frac{\sum_{i=1}^m \mathbb{I}(y^i = 1)}{m}$$

假设条件概率在给定  $y$  的情况下  $x$  的分布为混合高斯分布，则

$$P(X^i | y^i = 0) = P_{\mathcal{M}}(X^i; \vec{\mu}_0, \vec{\epsilon}), \quad P(X^i | y^i = 1) = P_{\mathcal{M}}(X^i; \vec{\mu}_1, \vec{\epsilon})$$

混合高斯分布的概率密度

$$P_{\mathcal{M}}(x; \vec{\mu}, \vec{\epsilon}) = \frac{1}{(2\pi)^{d/2} |\epsilon|^{1/2}} \exp\left(-\frac{1}{2}(x - \vec{\mu})\epsilon^{-1}(x - \vec{\mu})^T\right)$$

对数似然函数

$$L(\vec{\mu}_0, \vec{\mu}_1, \vec{\epsilon}) = \prod_{i=1}^m P_{\mathcal{M}}^{1-y^i}(X^i; \vec{\mu}_0, \vec{\epsilon}) P_{\mathcal{M}}^{y^i}(X^i; \vec{\mu}_1, \vec{\epsilon})$$

同理，对条件概率做极大似然估计，求出系数  $\mu_0, \mu_1, \epsilon$ ,

$$\frac{\partial \ell(\vec{\mu}_0, \vec{\mu}_1, \vec{\epsilon})}{\partial \vec{\mu}_0} = \sum_{i=1}^m \mathbb{I}(y^i = 0) \epsilon^{-1} (X^i - \vec{\mu}_0) = 0, \quad \vec{\mu}_0 = \frac{\sum_{i=1}^m \mathbb{I}(y^i = 0) X^i}{\sum_{i=1}^m \mathbb{I}(y^i = 0)}$$

同理，可以求出其他参数，

$$\vec{\mu}_0 = \frac{\sum_{i=1}^m \mathbb{I}(y^i = 0) X^i}{\sum_{i=1}^m \mathbb{I}(y^i = 0)}, \quad \vec{\epsilon} = \frac{1}{m} \sum_{i=1}^m (X^i - \mu_{y^i})(X^i - \mu_{y^i})^T$$

基于先验概率和似然概率，可以得到我们的目标后验概率，

$$y^* = \arg_y \max P(y|x) = \arg_y \max P(x|y)P(y)$$

## 朴素贝叶斯

朴素贝叶斯可用于处理离散属性的数据，或者将连续属性离散化。同理，朴素贝叶斯也是一种生成式学习器，其后验概率同样可以由先验概率和似然概率得到，

$$y^* = \arg_y \max P(y|x) = \arg_y \max P(x|y)P(y)$$

考虑 $y_i$ 满足多项分布，假设 $P(y^i = k) = \phi_k$ ,

$$P(y) = \prod_{k=1}^K \phi_k^{\mathbb{I}(y=k)}, \quad \phi_K = 1 - \sum_{k=1}^{K-1} \phi_k$$

利用极大似然法求到参数，

$$L(\phi_1, \phi_2, \dots, \phi_K) = \prod_{i=1}^m P(y^i), \quad \ell(\phi_1, \phi_2, \dots, \phi_K) = \sum_{i,k=1}^{m,K} \mathbb{I}(y^i = k) \log \phi_k$$

求梯度

$$\begin{aligned} \frac{\partial \ell(\phi_1, \phi_2, \dots, \phi_K)}{\partial \phi_k} &= \sum_{i=1}^m \left( \frac{\mathbb{I}(y^i = k)}{\phi_k} - \frac{\mathbb{I}(y^i = K)}{\phi_K} \right) = 0 \\ \frac{\phi_k}{\phi_K} &= \frac{\sum_{i=1}^m \mathbb{I}(y^i = k)}{\sum_{i=1}^m \mathbb{I}(y^i = K)}, \quad k = \{1, 2, \dots, K-1\} \end{aligned}$$

所以

$$\phi_k = \frac{\sum_{i=1}^m \mathbb{I}(y^i = k)}{m}, \quad k = \{1, 2, \dots, K\}$$

考虑条件概率 $P(x|y)$ ，假设 $X$ 的属性条件独立

$$P(X|y) = \prod_{i=1}^d P(x_i|y)$$

假设 $x_i$ 是离散属性，可以取 $\{1, 2, \dots, N_i\}$ ，对每个 $x_i$ ， $P(x_i|y = k)$ 满足多项分布，同理可以求得参数

$$\psi_{nk}^i = P(x_i = n|y = k) = \frac{\sum_{j=1}^m \mathbb{I}(y^j = k) \mathbb{I}(x_i^j = n)}{\sum_{j=1}^m \mathbb{I}(y^j = k)}, \quad k = \{1, 2, \dots, K\}, n = \{1, 2, \dots, N_i\}$$

## 拉普拉斯平滑

为避免概率变成0，将参数做如下调整

$$\phi_k = \frac{\sum_{i=1}^m \mathbb{I}(y^i = k) + 1}{m + K}, \quad \psi_{nk}^i = \frac{\sum_{j=1}^m \mathbb{I}(y^j = k) \mathbb{I}(x_i^j = n) + 1}{\sum_{j=1}^m \mathbb{I}(y^j = k) + N_i}$$